

**PEMODELAN RANTAI MARKOV PADA DINAMIKA
JUMLAH PENGGUNA AKTIF HARIAN E-LEARNING ITERA
PERIODE SEMESTER GANJIL 2025**

Laporan Tugas Besar Mata Kuliah Pemodelan Stokastik



Oleh:

- | | |
|----------------------------|-------------|
| 1. Efi Defiyati | (123450005) |
| 2. Romauli Oktavia Silaban | (123450014) |
| 3. Daffa Hadyan Navista | (123450025) |
| 4. Arini Puteri Elandra | (123450069) |
| 5. Hafsa Fazila Arradhi | (123450079) |
| 6. Rahmah Gustriana Deka | (123450102) |

Kelompok 3

Kelas RC

**PROGRAM STUDI SAINS DATA
FAKULTAS SAINS
INSTITUT TEKNOLOGI SUMATERA
2026**

DAFTAR ISI

DAFTAR ISI.....	ii
DAFTAR GAMBAR.....	iv
DAFTAR TABEL	v
BAB I PENDAHULUAN.....	1
1.1 Latar Belakang.....	1
1.2 Rumusan Masalah.....	2
1.3 Tujuan Penelitian.....	2
1.4 Manfaat Penelitian.....	3
1.4.1 Manfaat Akademis	3
1.4.2 Manfaat Praktis	3
BAB II TINJAUAN PUSTAKA.....	4
2.1 <i>E-Learning</i>	4
2.2 Data <i>Log</i> dan Aktivitas Pengguna	4
2.3 <i>Time Series</i> (Data Deret Waktu).....	5
2.4 Diskretisasi Data dengan <i>IQR</i>	5
2.5 Rantai Markov	6
2.6 Matriks Transisi.....	7
BAB III METODOLOGI PENELITIAN	9
3.1 Jenis Data.....	9
3.2 Teknik Pengumpulan Data	9
3.3 Variabel yang diamati.....	9
3.4 Diagram Alir.....	10
BAB IV HASIL DAN PEMBAHASAN	12

4.1 Deskripsi Data	12
4.2 Hasil Perhitungan atau Simulasi.....	13
4.2.1 Diskretisasi dengan IQR	13
4.2.2 Matriks Transisi	14
4.2.3 Distribusi Stasioner	15
4.3 Interpretasi Hasil.....	16
4.4 Diskusi	18
BAB V KESIMPULAN DAN SARAN	21
5.1 Kesimpulan.....	21
5.2 Saran	21
DAFTAR PUSTAKA.....	22

DAFTAR GAMBAR

Gambar 4.1 Pola data pengguna harian e-learning ITERA selama periode ganjil 2025.....	12
Gambar 4.2 Grafik perpindahan <i>state</i> jumlah pengguna harian <i>e-learning</i> ITERA selama periode semester ganjil 2025.....	13
Gambar 4.3 Diagram Perpindahan State penguna e-learning ITERA selama periode semester ganjil 2025.....	iv14

DAFTAR TABEL

Tabel 3.1 Diagram Alir Penelitian	9
Tabel 4.1 Statistik Deskriptif Data.....	11
Tabel 4.2 Hasil diskretisasi data DAU e-learning ITERA	12

BAB I

PENDAHULUAN

1.1 Latar Belakang

Perkembangan teknologi informasi telah mendorong transformasi signifikan dalam sistem pembelajaran di perguruan tinggi melalui pemanfaatan platform *e-learning* sebagai media utama dalam proses pembelajaran. Di Institut Teknologi Sumatera (ITERA), *e-learning* digunakan untuk mendukung berbagai aktivitas akademik, mulai dari distribusi materi, pengumpulan tugas, pelaksanaan evaluasi, hingga interaksi antara dosen dan mahasiswa. Keberadaan sistem ini tidak hanya meningkatkan fleksibilitas pembelajaran, tetapi juga menghasilkan data aktivitas pengguna dalam jumlah besar yang tersimpan dalam bentuk *log* harian. Data *log* tersebut mencerminkan jejak digital interaksi pengguna terhadap sistem *e-learning*, sehingga dapat digunakan sebagai sumber informasi untuk memahami pola keterlibatan pengguna secara kuantitatif. Data *log* merupakan salah satu sumber data yang dapat diolah menjadi informasi yang bernilai untuk mendukung kegiatan pendidikan dan pelatihan[1]. Oleh karena itu, analisis terhadap data *log* harian menjadi relevan untuk dilakukan sebagai dasar dalam memahami dinamika penggunaan *e-learning* secara lebih mendalam.

Salah satu indikator yang umum digunakan untuk merepresentasikan tingkat aktivitas pengguna adalah jumlah pengguna aktif harian (*Daily Active Users/DAU*), yang menggambarkan intensitas penggunaan sistem pada setiap periode waktu tertentu. Data ini bersifat agregat dan memberikan gambaran umum mengenai tingkat keterlibatan pengguna terhadap platform *e-learning*. Namun demikian, pola jumlah pengguna aktif harian cenderung menunjukkan fluktuasi yang signifikan dari waktu ke waktu. Fluktuasi ini dapat dipengaruhi oleh berbagai faktor internal dan eksternal, seperti motivasi, kondisi lingkungan belajar, interaksi, serta karakteristik tugas yang diberikan[2].

Untuk memahami pola perubahan aktivitas pengguna secara sistematis, diperlukan suatu pendekatan pemodelan yang mampu menggambarkan dinamika sistem dari waktu ke waktu. Salah satu pendekatan yang sesuai adalah Rantai Markov, yaitu suatu model stokastik yang digunakan untuk mengestimasi perubahan kondisi suatu

sistem dari waktu ke waktu. Pendekatan ini memanfaatkan matriks transisi Markov, di mana setiap elemen dalam matriks tersebut merepresentasikan probabilitas perpindahan dari satu keadaan ke keadaan lainnya, sehingga mampu menggambarkan pola dinamika sistem secara berurutan[3]. Oleh karena itu, penelitian ini dilakukan untuk memodelkan dinamika jumlah pengguna aktif harian *e-learning* ITERA menggunakan pendekatan Rantai Markov dengan memanfaatkan data *log* harian sebagai variabel utama, sehingga diharapkan dapat memberikan gambaran probabilistik mengenai pola perubahan tingkat aktivitas pengguna dan menjadi dasar dalam memahami dinamika penggunaan *e-learning* secara lebih terstruktur serta mendukung pengambilan keputusan berbasis data.

1.2 Rumusan Masalah

Berdasarkan latar belakang yang telah diuraikan, maka rumusan masalah dalam penelitian ini adalah:

1. Bagaimana pola dinamika jumlah pengguna aktif harian pada *e-learning* ITERA selama periode semester ganjil 2025?
2. Bagaimana proses pengelompokan jumlah pengguna aktif harian ke dalam beberapa *state* berdasarkan data *log* harian?
3. Bagaimana membangun model Rantai Markov berdasarkan data yang telah diklasifikasikan?
4. Bagaimana interpretasi probabilitas transisi antar *state* dalam menggambarkan dinamika aktivitas pengguna *e-learning*?

1.3 Tujuan Penelitian

Berdasarkan rumusan masalah yang telah diuraikan, maka tujuan penelitian ini adalah sebagai berikut

1. Menganalisis pola perubahan jumlah pengguna aktif harian pada *e-learning* ITERA.
2. Melakukan diskretisasi data *log* harian untuk mengelompokkan tingkat aktivitas pengguna ke dalam beberapa *state*.
3. Membangun model Rantai Markov untuk merepresentasikan perpindahan antar *state*.

4. Menginterpretasikan hasil probabilitas transisi untuk memahami dinamika perilaku pengguna *e-learning*.

1.4 Manfaat Penelitian

Dari penelitian yang dilakukan, manfaat yang diharapkan adalah sebagai berikut.

1.4.1 Manfaat Akademis

1. Menambah referensi dalam bidang analisis data pendidikan, khususnya terkait penerapan Rantai Markov pada data *e-learning*.
2. Memberikan kontribusi dalam pengembangan metode pemodelan data time series ber basis proses stokastik.
3. Menjadi acuan bagi penelitian selanjutnya yang berkaitan dengan analisis perilaku pengguna berbasis data *log*.

1.4.2 Manfaat Praktis

1. Memberikan informasi kepada pengelola *e-learning* ITERA mengenai pola penggunaan sistem oleh mahasiswa.
2. Menjadi dasar dalam pengambilan keputusan untuk meningkatkan keterlibatan pengguna (*user engagement*)
3. Membantu dalam perencanaan strategi pengelolaan dan pengembangan sistem *e-learning* berbasis data.

BAB II

TINJAUAN PUSTAKA

2.1 *E-Learning*

E-learning merupakan sistem pembelajaran berbasis teknologi informasi dan komunikasi yang memungkinkan proses belajar mengajar berlangsung tanpa keterbatasan ruang dan waktu. Dalam konteks perguruan tinggi, *e-learning* umumnya diimplementasikan melalui *Learning Management System* (LMS) yang menyediakan berbagai fitur akademik secara terintegrasi, seperti distribusi materi, penugasan, forum diskusi, dan evaluasi daring. Penggunaan LMS seperti *Moodle* telah menjadi standar di banyak perguruan tinggi di Indonesia karena fleksibilitasnya dalam mendukung berbagai model pembelajaran, baik secara sinkron maupun asinkron[4].

Efektivitas penggunaan *e-learning* di perguruan tinggi sangat dipengaruhi oleh faktor-faktor seperti kemudahan akses, kualitas konten, dan dukungan teknis dari institusi. Di sisi lain, keterlibatan pengguna (*user engagement*) merupakan indikator penting dalam mengukur keberhasilan implementasi *e-learning*. Tingkat keterlibatan ini dapat tercermin dari data *log* aktivitas pengguna yang tercatat pada sistem setiap harinya[5].

2.2 *Data Log dan Aktivitas Pengguna*

Data *log* merupakan catatan digital dari setiap aktivitas yang dilakukan pengguna dalam berinteraksi dengan suatu sistem. Dalam konteks *e-learning*, data *log* mencakup berbagai jenis interaksi, seperti pengaksesan materi, pengunduhan file, pengerjaan kuis, dan partisipasi dalam forum diskusi. Data *log* pada sistem *e-learning* menyimpan informasi yang sangat berharga untuk memantau kinerja platform sekaligus memahami pola perilaku pengguna secara kuantitatif[6].

Pola belajar mahasiswa pada platform LeADS UPNVJ menyatakan bahwa analisis data *log* aktivitas mahasiswa menggunakan pendekatan big data dan algoritma klasifikasi mampu mengidentifikasi waktu belajar yang paling aktif serta faktor-faktor yang mempengaruhi keterlibatan mahasiswa. Temuan tersebut menegaskan bahwa data *log* merupakan sumber informasi strategis yang dapat diolah menjadi

wawasan berbasis data (*data-driven insights*) untuk mendukung pengambilan keputusan di lingkungan pendidikan[7].

Salah satu turunan dari data *log* yang sering digunakan sebagai indikator aktivitas adalah *Daily Active Users* (DAU), yaitu jumlah pengguna unik yang mengakses sistem dalam satu hari. Nilai DAU mencerminkan intensitas penggunaan platform secara agregat dan dapat dianalisis sebagai data deret waktu (*time series*) untuk memahami pola perubahan aktivitas pengguna dari hari ke hari[7].

2.3 Time Series (Data Deret Waktu)

Data deret waktu (*time series*) merupakan sekumpulan data yang dikumpulkan atau diobservasi secara berurutan menurut waktu. Karakteristik utama dari data *time series* adalah adanya ketergantungan antara nilai satu pengamatan dengan nilai pengamatan berikutnya, sehingga analisis terhadap data jenis ini memerlukan pendekatan yang mempertimbangkan dimensi waktu secara eksplisit. Data *time series* yang bersifat acak dan fluktuatif, seperti data laju inflasi atau data pengguna aktif *platform* digital, sangat cocok dimodelkan menggunakan pendekatan proses stokastik, salah satunya Rantai Markov [8]

Dalam konteks penggunaan *e-learning*, data DAU merupakan data deret waktu yang mencerminkan fluktuasi aktivitas pengguna sepanjang periode akademik. Pola perubahan nilai DAU cenderung dipengaruhi oleh faktor-faktor periodik seperti awal semester, periode ujian, dan libur akademik, yang menjadikannya representasi yang tepat untuk dimodelkan secara stokastik guna memahami probabilitas perpindahan kondisi dari satu keadaan ke keadaan lainnya[8].

2.4 Diskretisasi Data dengan IQR

Diskretisasi atau kuantisasi merupakan proses pemetaan data kontinu ke dalam sejumlah nilai diskrit yang lebih terbatas. Proses ini dilakukan dengan menggantikan sekumpulan nilai kontinu $X = \{x_1, x_2, \dots, x_n\}$ menjadi himpunan nilai yang lebih kecil $R = \{r_1, r_2, \dots, r_k\}$, dengan $k < n$, di mana setiap nilai diskrit merepresentasikan beberapa nilai kontinu yang memiliki karakteristik serupa[9]. Dalam konteks analisis data, pendekatan ini digunakan untuk membentuk

kategori atau kelas tertentu sehingga memudahkan interpretasi dan pemodelan data, khususnya pada data kontinu yang kompleks .

Salah satu metode yang umum digunakan adalah *Interquartile Range* (IQR), yang membagi data berdasarkan sebaran kuartil, yaitu kuartil pertama (Q_1), median (Q_2), dan kuartil ketiga (Q_3). IQR dihitung sebagai selisih antara (Q_3) dan (Q_1), yang merepresentasikan rentang tengah data dan digunakan sebagai ukuran penyebaran yang relatif tidak sensitif terhadap *outlier*[10]. Dalam penerapannya, nilai IQR dapat dimanfaatkan untuk menentukan batas interval serta mengidentifikasi nilai ekstrem sehingga menghasilkan pembagian kategori yang lebih representatif terhadap distribusi data. Metode ini tidak memerlukan asumsi distribusi tertentu dan efektif digunakan pada data yang memiliki pencilan atau distribusi tidak normal[11], sehingga cocok diterapkan sebagai tahap pra proses dalam pembentukan *state* pada model Rantai Markov .

Dalam penelitian ini, klasifikasi data dilakukan menggunakan batas kuartil dengan tiga kategori utama, yaitu:

$$\begin{aligned} \text{State 1 (Rendah): } x &< Q_1 \\ \text{State 2 (Sedang): } Q_1 &< x < Q_3 \\ \text{State 3 (Tinggi): } x &> Q_3 \end{aligned} \tag{2.1}$$

2.5 Rantai Markov

Rantai Markov adalah suatu model probabilistik yang menggambarkan urutan kejadian di mana probabilitas setiap kejadian hanya bergantung pada keadaan saat ini, bukan pada serangkaian keadaan sebelumnya. Sifat ini dikenal sebagai sifat Markov atau sifat tanpa memori (*memoryless property*). Model tersebut termasuk dalam kerangka proses stokastik waktu diskrit dan telah diterapkan secara luas dalam berbagai bidang, mulai dari analisis keuangan, prediksi cuaca, hingga pemodelan perilaku pengguna sistem [8].

Rantai Markov dapat dilakukan untuk memprediksi pangsa pasar platform streaming online dan menemukan bahwa model ini efektif dalam menggambarkan pola perpindahan pengguna antar platform dalam kondisi *steady state*. Hal ini

mendukung relevansi penggunaan Rantai Markov dalam konteks analisis perilaku pengguna platform digital, termasuk *e-learning* [12]. Secara formal, suatu proses stokastik $\{X_t, t = 0, 1, 2, \dots\}$ dengan ruang *state* $S = \{s_1, s_2, \dots, s_n\}$ disebut Rantai Markov apabila memenuhi sifat Markov (*Markov Property*), yaitu:

$$P(X_{t+1} = j | X_t = i, X_{t-1} = i_{t-1}, \dots, X_0 = i_0) = P(X_{t+1} = j | X_t = i) \quad (2.2)$$

Keterangan:

X_t = *state* sistem pada waktu t

X_{t+1} = *state* sistem pada waktu berikutnya $t+1$

$i, j \in S$ = *state* asal dan *state* tujuan

Persamaan tersebut menyatakan bahwa probabilitas perpindahan ke *state* j hanya bergantung pada *state* saat ini i , bukan pada riwayat *state* sebelumnya. Probabilitas bersyarat $\{P(X_{t+1} = j | X_t = i)\}$ dalam Rantai Markov disebut probabilitas transisi satu langkah dan dikatakan stasioner, artinya probabilitas transisi tersebut tidak berubah seiring waktu [13].

2.6 Matriks Transisi

Frekuensi transisi merupakan tahap awal dalam pembentukan model Rantai Markov yang digunakan untuk mencatat jumlah perpindahan dari suatu *state* ke *state* lainnya berdasarkan data observasi [14]. Frekuensi ini disusun dalam bentuk matriks $F = [n_{ij}]$, di mana setiap elemen n_{ij} menyatakan banyaknya kejadian perpindahan dari *state* ke- i ke *state* ke- j . Matriks frekuensi transisi memberikan gambaran empiris mengenai pola perpindahan antar *state* dalam sistem yang diamati.

Selanjutnya, matriks frekuensi tersebut dinormalisasi untuk memperoleh matriks probabilitas transisi. Matriks probabilitas transisi dinotasikan sebagai $P = [p_{ij}]$, di mana setiap elemen p_{ij} menyatakan peluang berpindah dari *state* ke- i ke *state* ke- j . Nilai probabilitas ini diperoleh dengan membagi setiap elemen frekuensi dengan jumlah total frekuensi pada baris yang sama, sehingga dirumuskan sebagai:

$$p_{ij} = \frac{n_{ij}}{\sum_i n_{ij}} \quad (2.3)$$

Keterangan:

p_{ij} = probabilitas transisi dari *state-i* ke *state-j*

n_{ij} = frekuensi transisi dari *state-i* ke *state-j*

$\sum_i n_{ij}$ = frekuensi transisi total yang keluar dari *state-i*

Dengan demikian, setiap baris pada matriks probabilitas transisi memiliki jumlah bernilai satu, yang menunjukkan bahwa sistem pasti berpindah ke salah satu *state* pada langkah berikutnya[15]. Matriks ini menjadi dasar dalam analisis dinamika sistem, karena mampu merepresentasikan kecenderungan perpindahan antar *state* serta digunakan dalam perhitungan distribusi stasioner untuk melihat perilaku jangka panjang sistem.

BAB III

METODOLOGI PENELITIAN

3.1 Jenis Data

Penelitian ini menggunakan data sekunder berupa data *log* aktivitas harian pengguna platform *e-learning* ITERA. Data yang digunakan adalah agregat jumlah pengguna aktif harian (*Daily Active Users/DAU*), yaitu jumlah pengguna unik yang tercatat mengakses sistem *e-learning* dalam setiap hari selama periode pengamatan. Data ini bersifat kuantitatif dan merupakan data deret waktu (*time series*) harian.

3.2 Teknik Pengumpulan Data

Data dikumpulkan dari *log* sistem *e-learning* ITERA yang bersumber dari rekaman aktivitas pengguna (*user activity log*) selama periode semester ganjil tahun 2025. Pengumpulan data dilakukan melalui ekstraksi langsung dari basis data sistem *e-learning* dengan melibatkan koordinasi dengan pihak pengelola sistem. Data yang diperoleh kemudian diverifikasi untuk memastikan konsistensi dan kelengkapan rekaman harian.

3.3 Variabel yang diamati


Variabel utama yang diamati dalam penelitian ini adalah jumlah pengguna aktif harian (DAU) pada platform *e-learning* ITERA. Variabel ini digunakan sebagai representasi tingkat aktivitas pengguna dan selanjutnya diklasifikasikan ke dalam tiga *state* berbeda berdasarkan hasil diskretisasi, yaitu Trafik Rendah, Sedang, dan Padat.

Tabel 3.1 Variabel Penelitian

Nama Variabel	Jenis Variabel	Indikator / Pengukuran
Jumlah pengguna aktif harian (DAU)	Dependen	Jumlah pengguna aktif per hari pada platform <i>e-learning</i> ITERA
Klasifikasi trafik pengguna	Dependen (turunan)	Kategori hasil diskretisasi: Trafik Rendah, Sedang, Padat

3.4 Diagram Alir

Diagram alir penelitian pada Gambar 3.1 menggambarkan tahapan pelaksanaan penelitian secara sistematis dan terstruktur.



Gambar 3.1 Diagram Alir Penelitian

Diagram alir pada **Gambar 3.1** menggambarkan tahapan penelitian yang dilakukan secara sistematis dan berurutan. Proses dimulai dari tahap pengumpulan data, yaitu memperoleh data *Daily Active Users* (DAU) dari *e-learning* ITERA sebagai sumber utama penelitian. Setelah data diperoleh, dilakukan eksplorasi data untuk memahami karakteristik data, mengidentifikasi pola penggunaan, serta melihat kondisi awal data yang akan dianalisis. Selanjutnya dilakukan tahap prapemrosesan data untuk membersihkan data, menangani data yang tidak valid, dan memastikan kualitas data sebelum digunakan pada tahap analisis. Pada tahap ini juga dilakukan pengecekan validitas data, sehingga jika data belum valid maka dilakukan perbaikan kembali hingga data dinyatakan layak digunakan. Setelah data valid, proses dilanjutkan ke tahap pemodelan yang dimulai dengan diskretisasi data untuk mengelompokkan nilai DAU ke dalam beberapa state. Selanjutnya dihitung matriks transisi untuk mengetahui probabilitas perpindahan antar *state*, kemudian dilanjutkan dengan perhitungan distribusi stasioner untuk melihat kondisi

keseimbangan jangka panjang sistem. Tahap akhir adalah interpretasi hasil dan penarikan kesimpulan berdasarkan hasil analisis yang telah dilakukan.

BAB IV

HASIL DAN PEMBAHASAN


4.1 Deskripsi Data

Data yang digunakan dalam penelitian ini merupakan data jumlah pengguna aktif harian (*Daily Active Users* / DAU) pada platform *e-learning* ITERA selama periode semester ganjil tahun 2025 yaitu yang dari tanggal 24 Agustus - 26 Desember 2025. Data diperoleh dari *log* aktivitas harian pengguna yang tercatat pada sistem *e-learning*, sehingga setiap nilai merepresentasikan jumlah pengguna unik yang aktif mengakses platform pada hari tertentu dalam rentang waktu pengamatan. Data DAU merupakan data deret waktu (*time series*) yang disusun berdasarkan urutan waktu harian. Nilai ini digunakan sebagai indikator keterlibatan pengguna karena menunjukkan intensitas penggunaan platform dalam periode tertentu.

Tabel 4.1 Statistik Deskriptif Data

Statistik	Nilai
Jumlah Observasi	125
Minimum	229
Maksimum	5.348
Rata-rata	2219
Median	2123
Standar Deviasi	987.3147

Berdasarkan **Tabel 4.1** Statistika Deskriptif Data, hasil pengamatan jumlah pengguna aktif harian bersifat fluktuatif dengan nilai minimum 229 pengguna dan maksimum 5.348 pengguna. Pada awal semester, aktivitas pengguna mengalami peningkatan yang cukup tinggi hingga mencapai puncak pada akhir Agustus sampai awal September. Setelah itu, nilai DAU cenderung berfluktuasi pada tingkat menengah dan menurun menjelang akhir semester. Penurunan ini menunjukkan berkurangnya aktivitas akademik seiring berakhirnya perkuliahan. Visualisasi data pada Gambar 4.1 menunjukkan pola perubahan dari data.



Gambar 4.1 Pola data pengguna harian *e-learning* ITERA selama periode ganjil 2025

4.2 Hasil Perhitungan atau Simulasi


4.2.1 Diskretisasi dengan IQR

Data jumlah pengguna aktif harian (*Daily Active Users / DAU*) pada *e-learning* ITERA masih berbentuk kontinu sehingga perlu dilakukan proses diskretisasi sebelum dimodelkan menggunakan Rantai Markov. Berdasarkan hasil tersebut, maka batas interval untuk masing-masing *state* ditentukan sebagai berikut.

Tabel 4.2. Hasil diskretisasi data DAU *e-learning* ITERA

<i>State</i>	Kategori	Rentang DAU
<i>State 1</i>	Rendah	229 – 1647
<i>State 2</i>	Sedang	1650 – 2862
<i>State 3</i>	Padat	2885 – 5348

Lebih jelas grafik perubahan *statenya* dapat dilihat pada gambar dibawah ini.



Gambar 4.2 Grafik perpindahan *state* jumlah pengguna harian *e-learning* ITERA selama periode semester ganjil 2025

4.2.2 Matriks Transisi

Setelah setiap data DAU diklasifikasikan ke dalam *state*, langkah berikutnya adalah menghitung perpindahan antar *state* dari hari ke hari untuk membentuk matriks transisi. Pada proses Markov, probabilitas perpindahan suatu *state* hanya bergantung pada *state* saat ini dan tidak dipengaruhi oleh *state* sebelumnya[16] . Berikut adalah hasil dari matriks frekuensi transisi.


$$F_{ij} = \begin{bmatrix} 19 & 8 & 4 \\ 11 & 36 & 15 \\ 1 & 18 & 12 \end{bmatrix} \quad (4.1)$$

Dari matriks frekuensi transisi, diperoleh matriks peluang transisi sebagai berikut.

$$F_{ij} = \begin{bmatrix} 0,6129 & 0,2581 & 0,1290 \\ 0,1774 & 0,5806 & 0,2419 \\ 0,0323 & 0,5806 & 0,3871 \end{bmatrix} \quad (4.2)$$

Matriks probabilitas transisi terdiri dari tiga *state*, yaitu S_1, S_2 , dan S_3 , di mana setiap elemen menyatakan peluang perpindahan antar *state* dalam satu periode. Pada *state* S_1 , probabilitas tetap berada di S_1 sebesar 0,6129, berpindah ke S_2 sebesar 0,2581, dan ke S_3 sebesar 0,1290. Pada *state* S_2 , probabilitas tetap sebesar

0,5806, berpindah ke S_1 sebesar 0,1774, dan ke S_3 sebesar 0,2419. Sementara pada *state* S_3 probabilitas tetap sebesar 0,3871, berpindah ke S_1 sebesar 0,0323, dan ke S_2 sebesar 0,5806. Seluruh baris pada matriks memiliki jumlah probabilitas sebesar satu, sehingga memenuhi sifat matriks transisi pada rantai Markov. Dibawah ini diagram transisi dari kasus *e-learning* ITERA.



Gambar 4.3 Diagram Perpindahan *State* pengguna *e-learning* ITERA selama periode semester ganjil 2025

4.2.3 Distribusi Stasioner

Untuk mengetahui kecenderungan perilaku sistem dalam jangka panjang, dilakukan perhitungan distribusi stasioner berdasarkan matriks probabilitas transisi yang telah diperoleh. Hasil perhitungan distribusi stasioner adalah sebagai berikut.

$$\pi = [0,25 \quad 0,50 \quad 0,25] \quad (4.3)$$

State dengan nilai probabilitas terbesar menunjukkan kondisi yang paling dominan dalam jangka panjang. Berdasarkan hasil perhitungan, diperoleh distribusi stasioner sebesar $\pi_1 = 0,25$, $\pi_2 = 0,50$, dan $\pi_3 = 0,25$. Nilai tersebut merepresentasikan probabilitas jangka panjang sistem pada masing-masing *state* yang telah mencapai kondisi keseimbangan.

4.3 Interpretasi Hasil

Hasil visualisasi menunjukkan bahwa jumlah pengguna aktif harian (DAU) pada *e-learning* ITERA mengalami fluktuasi yang cukup jelas sepanjang periode pengamatan. Pada awal periode, sistem lebih sering berada pada kondisi Trafik Padat, kemudian secara bertahap mengalami penurunan menuju Trafik Sedang, dan pada bagian akhir periode lebih banyak didominasi oleh Trafik Rendah. Pola ini mengindikasikan bahwa aktivitas pengguna cenderung tinggi di awal perkuliahan, kemudian menurun seiring berjalannya waktu dan lebih stabil pada level rendah di akhir periode.

Berdasarkan matriks probabilitas transisi, terlihat bahwa setiap *state* memiliki kecenderungan untuk bertahan pada kondisi yang sama, ditunjukkan oleh nilai diagonal utama yang relatif lebih besar dibandingkan peluang transisi lainnya:

- a) Trafik Padat = 0.6129
- b) Trafik Sedang = 0.5806
- c) Trafik Rendah = 0.3871

Hal ini menunjukkan bahwa sistem cenderung memiliki persistensi *state*, terutama pada kondisi Trafik Padat dan Trafik Sedang. Namun, Trafik Rendah memiliki stabilitas yang lebih rendah, yang berarti kondisi ini lebih mudah berubah ke *state* lain.

Dari sisi perpindahan *state*, terdapat pola yang cukup menarik:

- a) Trafik Rendah memiliki peluang terbesar untuk tetap berada pada kondisi yang sama sebesar 0,6129. Namun, terdapat kemungkinan berpindah ke Trafik Sedang sebesar 0,2581 dan ke Trafik Padat sebesar 0,1290, yang menunjukkan bahwa peningkatan trafik umumnya terjadi secara bertahap.
- b) Trafik Sedang memiliki peluang terbesar untuk tetap berada pada kondisi yang sama sebesar 0,5806. Selain itu, kondisi ini juga memiliki kemungkinan berpindah ke Trafik Rendah sebesar 0,1774 maupun ke Trafik Padat sebesar 0,2419, sehingga dapat dikatakan sebagai kondisi transisi yang paling dinamis.
- c) Trafik Padat memiliki peluang sebesar 0,5806 untuk turun ke Trafik Sedang dan peluang sebesar 0,3871 untuk tetap berada pada kondisi padat. Hal ini

menunjukkan bahwa lonjakan trafik cenderung tidak bertahan lama dan lebih sering kembali ke kondisi sedang.

Matriks probabilitas transisi yang terbentuk pada penelitian ini merupakan matriks stokastik berukuran (3x3), di mana setiap elemen menyatakan peluang perpindahan antar state (Rendah, Sedang, dan Padat) dengan jumlah setiap baris bernilai satu. Berdasarkan hasil estimasi, matriks tersebut menunjukkan bahwa seluruh *state* saling terhubung satu sama lain, sehingga tidak terdapat *state* yang terisolasi, yang mengindikasikan sifat *irreducible*[17]. Selain itu, adanya nilai probabilitas pada diagonal utama (*self-transition*) seperti pada state Rendah (0,6129), Sedang (0,5806), dan Padat (0,3871) menunjukkan bahwa sistem memiliki kemungkinan untuk tetap berada pada *state* yang sama dalam satu langkah transisi, sehingga bersifat aperiodik[17]. Kombinasi kedua sifat tersebut pada ruang state berhingga menjadikan matriks transisi ini memenuhi kondisi rantai Markov ergodik, yang berarti sistem memiliki distribusi stasioner unik dan akan konvergen menuju keadaan keseimbangan jangka panjang [18].

Sementara itu, distribusi stasioner menunjukkan kondisi jangka panjang sistem, yaitu:

- a) S1 (Trafik Padat) = 0.25
- b) S2 (Trafik Sedang) = 0.50
- c) S3 (Trafik Rendah) = 0.25

Berdasarkan struktur matriks transisi, state “Sedang” berperan sebagai state perantara yang menjadi jalur utama perpindahan antar state lainnya. Hal ini menyebabkan setiap transisi antar state cenderung melalui state “Sedang” sebelum mencapai state “Rendah” atau “Padat”. Dengan demikian, dapat disimpulkan bahwa meskipun terdapat fluktuasi aktivitas yang cukup tinggi, pola penggunaan *e-learning* ITERA secara umum cenderung stabil pada tingkat penggunaan sedang, dengan lonjakan dan penurunan trafik yang terjadi secara periodik sesuai dinamika kegiatan akademik.

4.4 Diskusi

Hasil analisis menggunakan pendekatan Rantai Markov pada data DAU *e-learning* ITERA menunjukkan adanya pola dinamika pengguna yang tidak sepenuhnya acak, melainkan mengikuti kecenderungan transisi antar *state* (Trafik Padat, Sedang, dan Rendah). Temuan ini sejalan dengan penelitian sebelumnya yang menyatakan bahwa rantai Markov dapat digunakan untuk membangun profil penggunaan pada sistem *e-learning* berbasis web melalui identifikasi pola transisi antar aktivitas pengguna. Penelitian tersebut menunjukkan bahwa perilaku penggunaan platform *e-learning* dapat dianalisis melalui pola perpindahan antar kondisi yang terjadi secara berulang dan terstruktur[19]. Hal ini mengindikasikan bahwa penggunaan platform *e-learning* tidak berlangsung secara acak, melainkan mengikuti pola yang dapat diprediksi berdasarkan kebiasaan akses dan aktivitas akademik pengguna.

Jika dibandingkan dengan studi-studi sebelumnya pada analisis trafik sistem *e-learning*, *state* “menengah” (*moderate usage*) cenderung menjadi kondisi dominan dalam jangka panjang. Hal ini juga tercermin pada hasil distribusi stasioner dalam penelitian ini, di mana Trafik Sedang memiliki probabilitas tertinggi (0,50). Temuan ini sejalan dengan penelitian sebelumnya yang menunjukkan bahwa pola akses mahasiswa pada Learning Management System (LMS) cenderung berlangsung secara rutin dan berulang, dengan total akses yang stabil selama periode pembelajaran serta perbedaan intensitas yang tidak selalu ekstrem. Penelitian tersebut juga menemukan bahwa aktivitas akses LMS lebih banyak terjadi pada hari-hari akademik tertentu dan menunjukkan adanya pola penggunaan yang konsisten sebagai bagian dari proses belajar sehari-hari[20]. Kondisi ini menunjukkan bahwa sistem *e-learning* umumnya berada pada penggunaan moderat sebagai keadaan normal, sedangkan trafik tinggi hanya muncul pada waktu-waktu tertentu seperti menjelang ujian atau pengumpulan tugas. Hal ini mendukung hasil distribusi stasioner pada penelitian ini, di mana Trafik Sedang menjadi *state* dominan dalam jangka panjang, sehingga sistem pembelajaran daring tidak berada pada kondisi ekstrem secara terus-menerus, melainkan stabil pada tingkat penggunaan moderat.

Selain itu, hasil matriks transisi menunjukkan bahwa probabilitas terbesar berada pada diagonal utama, yang mengindikasikan adanya sifat persistensi *state*. Fenomena ini sejalan dengan penelitian sebelumnya yang menjelaskan bahwa model Markov digunakan untuk memahami pola navigasi pengguna, di mana halaman selanjutnya yang dikunjungi pengguna hanya bergantung pada halaman yang sedang dikunjunginya saat ini[19]. Pernyataan ini menunjukkan bahwa kondisi saat ini memiliki pengaruh besar terhadap kondisi berikutnya, sehingga sistem cenderung mempertahankan *state* yang sama dalam jangka pendek sebelum mengalami perubahan. Hal ini mendukung hasil penelitian ini bahwa jika sistem berada pada kondisi Trafik Sedang, maka besar kemungkinan kondisi tersebut akan tetap berada pada *state* yang sama pada hari berikutnya.

Sesuai dengan teori rantai Markov, bahwa distribusi stasioner adalah waktu rata-rata jangka panjang sistem berada pada *state* tersebut[21]. Sehingga *state* yang memiliki frekuensi kunjungan lebih tinggi dalam jangka panjang akan memiliki probabilitas stasioner yang lebih[21]. Oleh karena itu, *state* “Sedang” memiliki probabilitas stasioner terbesar yaitu sekitar 0.50, sedangkan *state* lainnya masing-masing sekitar 0.25. Hal ini mengindikasikan adanya periode tertentu ketika aktivitas pengguna menurun, yang berkaitan dengan jeda akademik atau masa transisi antar kegiatan perkuliahan. Temuan ini didukung penelitian sebelumnya yang menunjukkan bahwa terdapat periode tertentu dalam proses akademik ketika aktivitas belajar tidak berada pada puncaknya, melainkan menurun sementara karena adanya jeda pembelajaran atau masa transisi sebelum menghadapi tugas dan ujian berikutnya. Pada periode tersebut, intensitas akses terhadap platform *e-learning* cenderung lebih rendah karena tidak ada tuntutan akademik yang mendesak[22]. Kondisi ini mendukung hasil penelitian ini, di mana proporsi Trafik Rendah dalam distribusi stasioner masih cukup signifikan (0,25), sehingga menunjukkan bahwa penurunan aktivitas pengguna merupakan bagian normal dari dinamika penggunaan sistem *e-learning*.

Secara keseluruhan, hasil penelitian ini memperkuat temuan penelitian sebelumnya bahwa sistem *e-learning* memiliki pola penggunaan yang stabil dalam jangka panjang namun tetap fluktuatif dalam jangka pendek, dengan dominasi pada kondisi

penggunaan sedang yang dipengaruhi oleh siklus akademik. Hal ini terlihat dari distribusi stasioner yang menunjukkan bahwa Trafik Sedang memiliki probabilitas tertinggi, sehingga menjadi kondisi normal sistem. Peningkatan trafik biasanya terjadi saat deadline tugas, ujian, atau aktivitas akademik tertentu, sedangkan penurunan trafik muncul pada masa jeda perkuliahan atau saat tidak ada tuntutan akademik yang mendesak. Selain itu, probabilitas terbesar pada diagonal utama matriks transisi menunjukkan adanya persistensi *state*, yaitu kecenderungan sistem untuk mempertahankan kondisi saat ini sebelum berpindah ke *state* lain. Dengan demikian, penggunaan *e-learning* tidak bersifat acak, melainkan mengikuti pola yang stabil dan terstruktur sesuai dinamika kegiatan akademik.

BAB V

KESIMPULAN DAN SARAN

5.1 Kesimpulan

Berdasarkan hasil penelitian mengenai pemodelan Rantai Markov pada dinamika jumlah pengguna aktif harian (*Daily Active Users / DAU*) *e-learning* ITERA selama semester ganjil tahun 2025, diperoleh kesimpulan sebagai berikut:

1. Pola jumlah pengguna aktif harian *e-learning* ITERA selama semester ganjil 2025 menunjukkan fluktuasi yang mengikuti aktivitas akademik, dengan trafik padat di awal semester, sedang di pertengahan, dan rendah di akhir semester.
2. Pengelompokan data DAU dilakukan dengan metode IQR menjadi tiga *state*, yaitu Trafik Rendah, Trafik Sederang, dan Trafik Padat berdasarkan rentang jumlah pengguna harian.
3. Model Rantai Markov dibangun dari perpindahan antar *state* harian melalui matriks frekuensi transisi yang dinormalisasi menjadi matriks probabilitas transisi.
4. Hasil probabilitas transisi dan distribusi stasioner menunjukkan bahwa Trafik Sederang merupakan kondisi dominan jangka panjang dengan probabilitas sebesar 0,50 serta adanya kecenderungan sistem mempertahankan *state* yang sedang berlangsung.

5.2 Saran

Penelitian selanjutnya disarankan menggunakan periode data yang lebih panjang agar pola transisi pengguna dapat diamati secara lebih akurat dan representatif, serta mempertimbangkan penambahan variabel lain seperti jadwal ujian, pengumpulan tugas, atau kalender akademik untuk mengetahui faktor yang lebih spesifik yang memengaruhi perubahan trafik pengguna. Selain itu, penelitian juga dapat menggunakan metode perbandingan dengan model lain seperti Hidden Markov Model (HMM) atau metode peramalan time series agar hasil analisis dinamika penggunaan *e-learning* menjadi lebih komprehensif dan memiliki tingkat prediksi yang lebih baik.

DAFTAR PUSTAKA

- [1] E. Ikhsan *et al.*, “SISTEMASI: Jurnal Sistem Informasi Penerapan K-Means Clustering dari Log Data Moodle untuk Menentukan Perilaku Peserta pada Pembelajaran Daring.” [Online]. Available: <http://sistemasi.ftik.unisi.ac.id>
- [2] J. Hu and W. Xiao, “What are the influencing factors of online learning engagement? A systematic literature review,” 2025, *Frontiers Media SA*. doi: 10.3389/fpsyg.2025.1542652.
- [3] A. Zaki *et al.*, “Model Rantai Markov dan Model ARIMA serta Kombinasinya dalam Memprediksi Curah Hujan di Kota Makassar,” 2018. [Online]. Available: <http://www.ojs.unm.ac.id/jmathcos>
- [4] M. Muliadi and H. Elmunsyah, “Pengaruh Feature E Learning dan Ketertarikan User Terhadap Peningkatan Penguasaan Teknologi Pembelajaran Pasca Pandemic Covid 19,” *Jurnal Ilmiah Profesi Pendidikan*, vol. 9, no. 2, pp. 847–864, May 2024, doi: 10.29303/jipp.v9i2.2226.
- [5] D. Defriansyah, D. Sari, and R. Puspitasari, “MOTIVASI DAN KETERLIBATAN DALAM LINGKUNGAN BELAJAR DIGITAL WAWASAN DARI PSIKOLOGI PENDIDIKAN”.
- [6] H. Karmila and H. Saptono, “Tampilan Implementasi Visualisasi Log Server Web dengan ELK Stack_ Analisis Kasus Log Akses pada Sistem Elena di Sekolah Tinggi Teknologi Terpadu Nurul Fikri”.
- [7] N. Irzavika, K. W. Gusti, M. T. Abdurachman, and B. Saputra, “Analisis Pola Belajar Mahasiswa Pada Platform Pembelajaran Daring (Studi Kasus: LeADS UPNVJ),” *Jurnal Nasional Teknologi dan Sistem Informasi*, vol. 11, no. 3, pp. 226–234, Dec. 2025, doi: 10.25077/teknosi.v11i3.2025.226-234.
- [8] J. Riyono, C. E. Pujiastuti, and A. L. Riyana Putri, “Forecasting Laju Inflasi Indonesia Menggunakan Rantai Markov,” *Jurnal Sains Matematika dan Statistika*, vol. 8, no. 1, p. 1, Jan. 2022, doi: 10.24014/jsms.v8i1.14767.

- [9] N. Senavirathne and V. Torra, "Rounding based continuous data discretization for statistical disclosure control," *J. Ambient Intell. Humaniz. Comput.*, vol. 14, no. 11, pp. 15139–15157, Nov. 2023, doi: 10.1007/s12652-019-01489-7.
- [10] A. ur Rehman and S. B. Belhaouari, "Unsupervised outlier detection in multidimensional data," *J. Big Data*, vol. 8, no. 1, Dec. 2021, doi: 10.1186/s40537-021-00469-z.
- [11] C. S. K. Dash, A. K. Behera, S. Dehuri, and A. Ghosh, "An outliers detection and elimination framework in classification task of data mining," *Decision Analytics Journal*, vol. 6, Mar. 2023, doi: 10.1016/j.dajour.2023.100164.
- [12] D. R. Permatasari and A. I. Tarigan, "PENERAPAN RANTAI MARKOV UNTUK MENGANALISIS PERILAKU PERPINDAHAN MEREK PLATFORM STREAMING ONLINE", doi: 10.33830/saintek.v1i1.10038.2024.
- [13] A. P. Nabila, C. Maharani, N. S. Putri, Z. R. Pangesti, B. Mardhotillah, and P. Matematika, "Analisis Rantai Markov untuk Mengetahui Peluang Perpindahan Platform E-Commerce yang dipilih Mahasiswa Matematika Markov Chain Analysis to Find Out Opportunities for Switching E-Commerce Platforms Chosen by Mathematics Students," vol. 3, no. 1, p. 2024, doi: 10.22437/multiproximity.v3i1.40623.
- [14] J. R. Eastman and J. He, "A regression-based procedure for markov transition probability estimation in land change modeling," *Land (Basel)*, vol. 9, no. 11, pp. 1–12, 2020, doi: 10.3390/land9110407.
- [15] A. Martina, F. Muhtarulloh, A. S. Awalluddin, and R. Cahyandari, "Membangun Matriks Peluang Transisi Markov Multivariat dan Analisisnya pada Data COVID-19 di Indonesia."

- [16] D. Denisov, D. Korshunov, and V. Wachtel, "Markov chains on $\mathbb{Z}^+$: analysis of stationary measure via harmonic functions approach," *Queueing Syst.*, vol. 91, no. 3–4, pp. 265–295, Apr. 2019, doi: 10.1007/s11134-019-09602-5.
- [17] S. Olanrewaju, "The Performance Measure Analysis on the Irreducibility in Markov Chain States Classification," *Available online www.jsaer.com Journal of Scientific and Engineering Research 109 Journal of Scientific and Engineering Research*, vol. 2021, no. 12, pp. 109–117, [Online]. Available: www.jsaer.com
- [18] S. Biswas, "Various proofs of the Fundamental Theorem of Markov Chains," Apr. 2022, [Online]. Available: <http://arxiv.org/abs/2204.00784>
- [19] A. Marques and O. Belo, "Discovering Student web Usage Profiles Using Markov Chains," *The Electronic Journal of e-Learning*, vol. 9, pp. 63–74, 2011, [Online]. Available: www.ejel.org
- [20] A. M. Abdullahi, M. Makhtar, and S. Safie, "The patterns of accessing learning management system among students," *Indonesian Journal of Electrical Engineering and Computer Science*, vol. 13, no. 1, pp. 15–21, Jan. 2019, doi: 10.11591/ijeecs.v13.i1.pp15-21.
- [21] D. A. Levin, Y. Peres, and E. L. Wilmer, "Markov Chains and Mixing Times, second edition."
- [22] Q. Nguyen, S. Thorne, and B. Rienties, "How do students engage with computer-based assessments: impact of study breaks on intertemporal engagement and pass rates," *Behaviormetrika*, vol. 45, no. 2, pp. 597–614, Oct. 2018, doi: 10.1007/s41237-018-0060-1.